



Tema 18: Deep Learning



Contenidos de la sesión

- Introducción
- La convolución
- Redes Convolucionales
- Entrenamiento de CNNs
- Transfer Learning
- Aplicaciones



Introducción






Lots of data & train time
Subject to overfitting
Universal problem solvers
Importance of weights - backprop

Empezemos por algo
“sencillo”: quiero
clasificar imágenes




Approach Clásico



- Approach genérico
- Requiere gran entendimiento de imágenes/vídeo
 - No funcionaba muy bien

Y si usamos redes de
neuronas?



Convolución




0	0	0	0	0	0	0
0	60	113	56	139	85	0
0	73	121	54	84	128	0
0	131	99	70	129	127	0
0	80	57	115	69	134	0
0	104	126	123	95	130	0
0	0	0	0	0	0	0


Kernel

0	-1	0
-1	5	-1
0	-1	0

114				

- Detecta patrones en secciones de la imagen
- Durante el entrenamiento, la red aprende los pesos del kernel
- Parámetros clave:
 - Kernel size
 - Stride
 - Padding






Pruébalo!

<https://setosa.io/ev/image-kernels/>

- **Detectan patrones espaciales:** son excelentes para identificar patrones locales como bordes, texturas y formas, que luego combinan para entender estructuras más complejas.
- **Reducción de parámetros:** usan los mismos filtros (pesos compartidos) en distintas partes de la imagen, lo que reduce drásticamente el número de parámetros respecto a una red completamente conectada.
- **Invariancia a traslaciones pequeñas:** gracias al uso de *pooling*, las CNNs son robustas frente a pequeños desplazamientos o deformaciones en la imagen.
- **Especializadas en imágenes (y más):** aunque nacieron para imágenes, también se usan en audio, series temporales y procesamiento de texto.



- Each slice detects a certain feature / activation map
- A convolutional layer is a group of activation maps


3x3

0.91	0.32	0.07
0.73	0.26	0.81
0.53	0.68	0.14

5x5

0.27	0.64	0.44	0.84	0.29
0.28	0.06	0.89	0.99	0.33
0.64	0.67	0.08	0.38	0.03
0.04	0.31	0.16	0.57	0.08
0.87	0.85	0.97	0.71	0.96

Kernel size





Stride

Image

0	0	0	0	0	0	0
0						0
0						0
0						0
0						0
0						0
0	0	0	0	0	0	0

Padding

La convolución



La convolución

0	0	0	0	0	0	...
0	156	155	156	158	158	...
0	153	154	157	159	159	...
0	149	151	155	158	159	...
0	146	146	149	153	158	...
0	145	143	143	148	158	...
...	...	...	...	...	...	...

Input Channel #1 (Red)

0	0	0	0	0	0	...
0	167	166	167	169	169	...
0	164	165	168	170	170	...
0	160	162	166	169	170	...
0	156	156	159	163	168	...
0	155	153	153	158	168	...
...	...	...	...	...	...	...

Input Channel #2 (Green)

0	0	0	0	0	0	...
0	163	162	163	165	165	...
0	160	161	164	166	166	...
0	156	158	162	165	166	...
0	155	155	158	162	167	...
0	154	152	152	157	167	...
...	...	...	...	...	...	...

Input Channel #3 (Blue)

-1	-1	1
0	1	-1
0	1	1

Kernel Channel #1



310

1	0	0
1	-1	-1
1	0	-1

Kernel Channel #2



-170

0	1	1
0	1	0
1	-1	1

Kernel Channel #3



325


+ 1 = 466



Bias = 1

Output

-25	466			...
				...
				...
				...
...	...	...	...	...




Redes Convolucionales



- Presentación de las **Redes Neuronales Convolucionales (CNN)**.

1998



Yann LeCun



Yoshua Bengio



- Uso de **tarjetas gráficas** (GPU) para paralelización en el entrenamiento de Redes Neuronales.
- Permiten acelerar de manera drástica el entrenamiento en cantidades ingentes de datos.





ImageNet Classification with Deep Convolutional Neural Networks



Alex Krizhevsky
University of Toronto
kriz@cs.utoronto.ca



Ilya Sutskever
University of Toronto
ilya@cs.utoronto.ca



Geoffrey E. Hinton
University of Toronto
hinton@cs.utoronto.ca





















- Reduce el tamaño
- Extrae los valores más dominantes (max pooling)
- Elimina el ruido
- No tiene parámetros!




experiment








a Retinotopy in the macaque





b Ocular dominance in the macaque





c Orientation preference in the tree shrew






Entrenamiento de CNNs





- Los datos pueden estar en aceleradores especializados (GPUs)
- Los tensores poseen las mismas optimizaciones de un array



Classified images dataset (ImageNet 256×256)



About


The dataset consists of 540,000 high-quality images at 256×256 resolution grouped into 1,000 unique categories (animals, objects, plants, vehicles, etc...).

Files
2025721 files

Size
167.62 GB



Los datasets de imágenes/videos suelen ser un problema en terminos de almacenamiento

La solución?




Concepto de un tensor.


- Los batches de imágenes son **Tensores** de dimensión (C x W x H).
- Los batches de imágenes son **Tensores** de dimensión (B x C x W x H).
- Las Redes Neuronales se alimentan de Tensores.



Las GPUs estan optimizadas para operaciones con tensores





GPU development at Nvidia since 2010



Nvidia Geforce/Titan	GFLOPS (FP32)	Memory transfer rate (GByte/s)	Memory capacity (GiByte)	GFLOPS per GByte/s
Fermi (GTX 580)	1.581	192,4	1,5	8,2
Kepler (GTX Titan Black)	5.645	336,4	6,0	16,8
Maxwell (GTX Titan X)	6.605	336,5	12,0	19,6
Pascal (Titan Xp)	12.150	547,6	12,0	22,2
Volta (Titan V)	14.899	652,8	12,0	22,8
Turing (Titan RTX)	16.312	672,1	24,0	24,3
Ampere (RTX 3090Ti)	40.000	1.008,2	24,0	39,7
Lovelace (RTX 4090)	82.575	1.008,2	24,0	81,9
Blackwell (RTX 5090)	104.883	1.792,0	32,0	58,5



Notes: For a long time, the ratio of arithmetic operations to memory throughput at Nvidia only knew one direction: up. Kepler made the biggest jump, followed by Ampere. Blackwell ends the series due to the only minimal increase in arithmetic performance compared to Lovelace

- Las CNNs antiguas tenían capas de clasificación al final en formato flatten, los cuales concentraban muchos parámetros
- Las CNNs más modernas usan capas de GAP (Global Average Pooling) en su lugar



Muchas mas técnicas han ido apareciendo según pasaba el tiempo, como los módulos de inception o las resnets

An example of an Inception module



Trabajar con imágenes no es sencillo



- Variabilidad entre clases

Trabajar con imágenes no es sencillo



- Variabilidad entre clases
- Luces, sombras etc

Trabajar con imágenes no es sencillo




- Variabilidad entre clases
- Luces, sombras etc
- Occlusion

Trabajar con imágenes no es sencillo




- Variabilidad entre clases
- Luces, sombras etc
- Occlusion
- Deformaciones

Trabajar con imágenes no es sencillo



Los objetos en 3D tienen más de un ángulo, como generalizamos?

Solución: Data Augmentation




Transfer Learning




ML Tradicional

- Un modelo para cada tarea
- Independientes unos de otros
- No hay transferencia de conocimiento




Con Transfer Learning

- Acelera el aprendizaje de nuevas tareas gracias a la transferencia de conocimiento
- Más rápido, menos datos




Transfer Learning




Una manera clásica de hacer transfer learning se basa en congelar los pesos de las capas convolucionales y hacer fine tuning de la capa de clasificación

Transfer Learning Overview



En otras circunstancias, podemos hacer fine tuning de algunas de las capas convolucionales también.



Especialmente útil cuando no
tenemos gran cantidad de datos para
pode entrenar nuestra propia CNN
nosotros

Aplicaciones



Detección de enfermedades

Our model, CheXNet, is a 121-layer convolutional neural network that inputs a chest X-ray image and outputs the probability of pneumonia along with a heatmap localizing the areas of the image most indicative of pneumonia.

We train CheXNet on the recently released ChestX-ray14 dataset, which contains 112,120 frontal-view chest X-ray images individually labeled with up to 14 different thoracic diseases, including pneumonia. We use dense connections and batch normalization to make the optimization of such a deep network tractable.

5v3 [cs.CV] 25 Dec 2017

CheXNet: Radiologist-Level Pneumonia Detection on Chest X-Rays with Deep Learning

Pranav Rajpurkar^{*1} Jeremy Irvin^{*1} Kaylie Zhu¹ Brandon Yang¹ Hershel Mehta¹ Tony Duan¹ Daisy Ding¹ Aarti Bagul¹ Robyn L. Ball² Curtis Langlotz³ Katie Shpanskaya³ Matthew P. Lungren³ Andrew Y. Ng¹

Abstract

We develop an algorithm that can detect pneumonia from chest X-rays at a level exceeding practicing radiologists. Our algorithm, CheXNet, is a 121-layer convolutional neural network trained on ChestX-ray14, currently the largest publicly available chest X-ray dataset, containing over 100,000 frontal-view X-ray images with 14 diseases. Four practicing academic radiologists annotate a test set, on which we compare the performance of CheXNet to that of radiologists. We find that CheXNet exceeds average radiologist performance on the F1 metric. We extend CheXNet to detect all 14 diseases in ChestX-ray14 and achieve state of the art results on all 14 diseases.



Input
Chest X-Ray Image

CheXNet
121-layer CNN

Output
Pneumonia Positive (85%)



Input
Chest X-Ray Image

CheXNet
121-layer CNN

Output
Pneumonia Positive (85%)





105 km/h

Conducción autónoma





2500 m



Transferencia de estilo









EBIS Business
Techschool

www.ebiseducation.com

