



Tema 18.2: LLMs Multimodales y LLMs en Producción

Contenidos

- Introducción a los LLMs Multimodales
- El camino hacia los LLMs multimodales
 - CNNs
 - Yolo
 - CLIP
 - Stable Diffusion
 - Generación Video
 - Generación Audio
- GenAI Providers
- Buenas prácticas para usar LLMs en producción
- LLMs en Data Science
- Ejercicio Text-to-SQL
- Ejercicios Opcionales




LLMs Multimodales




¿Qué significa “Multimodal”?


Capacidad de procesar y/o generar múltiples tipos de datos:
texto, imagen, audio, vídeo.



Acepta imagen/audio
→ genera texto




Acepta texto →
genera imagen/audio



Cualquier modalidad
↔ cualquier modalidad



Genera una imagen de un animal fantástico al estilo de un diagrama de leonardo da vinci.



Reconocimiento de imágenes: GPT-Vision

¿Qué ves aqui?

Veo un barco de juguete con estética romana, con una vela que lleva el texto "SPQR" y un emblema imperial. Tiene remeros a ambos lados, un mástil central con bandera roja y varias figuras a bordo. Está colocado sobre una alfombra negra en el salón, junto a un puff y muebles modernos. Parece un juguete tipo Playmobil de una galera romana.




Creación de Imágenes: Nano Banana



<https://aistudio.google.com>



Creación de Imágenes II: Nano Banana



<https://aistudio.google.com>



Creación de Imágenes III: Nano Banana



<https://aistudio.google.com>



Solo Texto



GPT-3.5, Claude 1

2022

2022

Visión Añadida



GPT-4V,
Claude 3 Vision

2023

2023

Nativo Multimodal



GPT-4o,
Gemini 1.5/2.0

2024

2024

Omnimodal + Agentes



Voz real-time,
computer use

2025

2025

El camino hacia los LLMs multimodales



¿Cómo conseguimos que una red “vea” una imagen?

CNNs

La imagen deja de ser píxeles y se convierte en características: bordes, texturas, formas y objetos.



CNNs



ImageNet Classification with Deep Convolutional Neural Networks


Alex Krizhevsky
University of Toronto
kriz@cs.utoronto.ca

Ilya Sutskever
University of Toronto
ilya@cs.utoronto.ca

Geoffrey E. Hinton
University of Toronto
hinton@cs.utoronto.ca


Abstract

We trained a large, deep convolutional neural network to classify the 1.2 million high-resolution images in the ImageNet LSVRC-2010 contest into the 1000 different classes. On the test data, we achieved top-1 and top-5 error rates of 37.5% and 17.0% which is considerably better than the previous state-of-the-art. The neural network, which has 60 million parameters and 650,000 neurons, consists of five convolutional layers, some of which are followed by max-pooling layers, and three fully-connected layers with a final 1000-way softmax. To make training faster, we used non-saturating neurons and a very efficient GPU implementation of the convolution operation. To reduce overfitting in the fully-connected layers we employed a recently-developed regularization method called “dropout” that proved to be very effective. We also entered a variant of this model in the ILSVRC-2012 competition and achieved a winning top-5 test error rate of 15.3%, compared to 26.2% achieved by the second-best entry.



Video recomendado:
https://www.youtube.com/watch?v=UZDiGooFs54&ab_channel=WelchLabs






Artículo sobre la evolución de arquitecturas Deep Learning para clasificación de imágenes:
<https://ai.plainenglish.io/imagenet-the-rise-of-deep-neural-network-architectures-for-image-classification-alexnet-713df0500e7f>



Imagenet challenge




Escalar es la solución! La evolución de hardware ha permitido entrenar modelos con más parámetros


	 LeNet-5	 AlexNet	 GPT-3	 GPT-4	
YEAR	1998	2012	2020	2023	2030
TRAINING DATA	· MNIST Dataset · 60k training examples · 10 classes	· ImageNet Dataset (ILSVRC) · 1.2M training examples · 1000 classes	· Common Crawl, WebText, Wikipedia, others · ~500B training tokens · ~100k unique tokens	· ~13T training tokens*	All the datas
TRAINING COMPUTE	· Pentium II CPU · ~0.27 GFLOPs	· Dual Nvidia GTX 580 · 3162 GFLOPs	· 10,000 Nvidia V100 GPUs · 1+ ExaFLOPs	· 25,000 Nvidia A100s GPUs* · ~4+ ExaFLOPs	All the computers
ALGORITHM	· ~60k Parameters · 5 Layers · Sigmoid Activation Function	· ~60M Parameters · 8 Layers · ReLU Activation Function · Dropout	· 175B Parameters · 96 Layers · Transformers	· 1T+ Parameters* · *120 Layers · Transformers	All the algorithms



Convolution Neural Network (CNN)



- Las primeras capas de la red se encargan de procesar información de bajo nivel, como líneas o curvas; mientras que las últimas capas se encargan de información de alto nivel, como una cara o la silueta de un animal.



- La operación de convolución consiste en la combinación lineal de una ventana de píxeles de una imagen.
- Para ello hay dos elementos fundamentales:
- Imagen de entrada: Una matriz bidimensional de datos (normalmente normalizada a $[-1, 1]$ o $[0, 1]$).
- Filtro o kernel: Una matriz (normalmente de 3×3 o 5×5) con la que se realizará la combinación lineal de los elementos de la imagen.

Input

2	1	4	0
1	2	2	0
3	1	2	1
0	0	-1	1

Kernel

0	1	-1
0	1	2
0	1	0


Output

4	8
5	5



CNN – Capa de pooling

- La capa de pooling se coloca normalmente después de una capa convolucional.
- Su objetivo es reducir las dimensiones espaciales del mapa de características, manteniendo la información más relevante para las siguientes capas.
- Para ello, resume pequeñas regiones de la imagen mediante operaciones estadísticas.
- Las más comunes son:
 - Max Pooling: se queda con el valor máximo de cada región.
 - Average Pooling: calcula la media de cada región.



¿Cómo detectamos objetos en tiempo real?

YOLO

De clasificar imágenes a localizar objetos en imágenes y vídeo: qué hay y dónde está.




YOLO



YOLO – You Only Look Once

- YOLO significa “You Only Look Once” y es una familia de modelos usada para detección de objetos en imágenes y vídeo.
- Su objetivo es detectar qué objetos aparecen y dónde están mediante cajas delimitadoras.
- A diferencia de enfoques más lentos, YOLO analiza la imagen en una sola pasada, por eso es muy rápido.
- Esto lo hace especialmente útil para aplicaciones en tiempo real, como:
 - cámaras de seguridad
 - vehículos autónomos
 - control industrial
 - análisis de vídeo
 - conteo y seguimiento de objetos...




Ejemplo proyecto detectar jugadores futbol con YOLO:
<https://github.com/alexoli97/FootballTrackingProject>



YOLO – Ejemplo



<https://huggingface.co/spaces/Ultralytics/YOLO26>



Texto, imagen, audio y vídeo son distintos... pero el modelo necesita compararlos

1. El texto se convierte en tokens
2. Las imágenes se convierten en embeddings visuales
3. El audio se convierte en representaciones de señal


El objetivo es llevar todo a un espacio común




Recordemos que eran los Embeddings

Modelos que permiten convertir **información textual** en información numérica

- Compacta
- Preservando el contenido
- Donde poder realizar operaciones de búsqueda






¿Cómo conectamos imágenes y lenguaje?

CLIP

Una imagen y su descripción empiezan a “hablar el mismo idioma” en un espacio semántico compartido.




- CLIP (Contrastive Language–Image Pretraining) es un modelo de OpenAI que aprende a relacionar imágenes con texto.
- Se entrena con millones de pares imagen + descripción, aprendiendo qué textos encajan mejor con qué imágenes.
- Su objetivo no es memorizar etiquetas cerradas, sino construir un espacio compartido donde imágenes y frases similares quedan cerca.
- Permite tareas zero-shot: reconocer conceptos nuevos sin reentrenar el modelo, usando descripciones en lenguaje natural.
- Ejemplo: en vez de entrenar un clasificador específico para “perro”, “gato” o “coche”, se le pueden dar textos candidatos y CLIP elige cuál encaja mejor con la imagen.
- Es una pieza clave para la IA multimodal porque conecta visión + lenguaje en una misma representación.
- **CLIP demostró que entrenar con muchísimos pares imagen + texto permitía hacer tareas visuales sin entrenar un clasificador específico para cada una**



¿Cómo funciona CLIP?

CLIP (Contrastive Language–Image Pretraining) aprende a relacionar imágenes y texto en un mismo espacio vectorial mediante entrenamiento contrastivo.



5. Uso (Zero-shot)

Imagen nueva

Codificador de imagen

Similitud con textos candidatos

"un gato"	0.05
"un perro"	0.92
"un coche"	0.03
"una playa"	0.10

Predicción: "un perro"

¿Qué permite CLIP?

- Clasificación de imágenes
- Geolocalización
- Reconocimiento de acciones
- OCR y más, sin reentrenar

💡 Idea clave: CLIP alinea imágenes y texto en un mismo espacio semántico para entender conceptos de forma conjunta.

Encoder	Descripción	Usado por
ViT	El estándar. Patches 14x14 o 16x16 px	GPT-4V, LLaVA
SigLIP	Más eficiente que CLIP	Gemini, PaLI
CLIP	El pionero de OpenAI	DALL-E, SD
EVA-CLIP	Mejor transferencia	InternVL

¿Cómo se fusionan texto e imagen en un LLM multimodal?

Tres estrategias principales para combinar modalidades

1 FUSIÓN TEMPRANA (Early Fusion)


Texto e imagen se combinan desde el inicio como una única secuencia.



★ Integración profunda desde el principio. Mayor coste computacional.

2 FUSIÓN INTERMEDIA (Cross-Attention)

El LLM atiende a los tokens visuales mientras genera la respuesta.



★ Muy utilizada en modelos vision-language. Buen equilibrio entre rendimiento y eficiencia.

3 FUSIÓN TARDÍA (Late Fusion)

Cada modalidad se procesa por separado y luego se combinan los resultados.



★ Más simple y eficiente, pero con menor razonamiento conjunto.



IDEA CLAVE

La multimodalidad no es solo aceptar imágenes: es decidir cómo se conectan sus representaciones con el razonamiento del modelo.



¿Cómo generamos imágenes desde texto?

Stable Diffusion

El lenguaje empieza a producir contenido visual: de un prompt a una imagen guiada por texto.



Stable Diffusion



- Stable Diffusion es un modelo generativo capaz de crear imágenes a partir de una descripción en texto.
- Su idea principal es partir de ruido y eliminarlo paso a paso hasta obtener una imagen coherente con el prompt.
- El texto se convierte primero en una representación numérica que guía la generación.
- El modelo trabaja en un espacio latente comprimido, no directamente sobre la imagen completa.
- Durante la difusión inversa, una red elimina ruido progresivamente siguiendo la condición del texto.
- Al final, un decoder transforma la representación latente limpia en la imagen final.
- Stable Diffusion es un puente natural hacia los modelos multimodales: conecta lenguaje, imagen y generación de contenido.




El punto de partida: ruido en el espacio latente



References: "Stable Diffusion for Scalable Denoising Diffusion Probabilistic Models," to introduce the Stable Diffusion method. URL: [arXiv:2201.04558](https://arxiv.org/abs/2201.04558)






El ruido se añade secuencialmente en cada paso.

El predictor de ruido estima el ruido total añadido hasta cada paso.





La imagen se reconstruye a partir del ruido.

¿Es así realmente como funciona Stable Diffusion?


- **No realmente 😊**
- La idea de difusión es correcta, pero Stable Diffusion no la aplica directamente sobre los píxeles.
- En lugar de trabajar con la imagen completa, la comprime en una representación llamada espacio latente (representación numérica comprimida de una imagen)
- En ese espacio latente ocurre el proceso de difusión:
- ruido → latente cada vez menos ruidoso → latente limpio
- Después, un decoder transforma ese latente limpio en la imagen final.
- Esto hace que Stable Diffusion sea mucho más eficiente en memoria y cómputo.



¿Cómo funcionan los Diffusion Models?


1. FASE DE ENTRENAMIENTO

Aprender a añadir ruido



2. FASE DE GENERACIÓN

Eliminar ruido paso a paso



Idea clave: En entrenamiento se añade ruido a imágenes limpias y el modelo aprende a predecirlo. En generación, partimos de ruido puro y el modelo va eliminándolo paso a paso.



Modelo	Mejor para	Texto	Calidad
GPT Image 2	Benchmark general / diseño / composición	Bueno	★★★★★
Nano Banana Pro / Gemini 3 Pro Image	1536px	Bueno	★★★★★
Midjourney v7 (Jun 25)	Estética / dirección visual	Regular+	★★★★☆
Ideogram	Texto / logos / carteles	Bueno	★★★★
FLUX / Open weights	Self-hosting / control / privacidad	Bueno	★★★★

Lo que YA funciona

- Texto legible en imágenes
- Fotorealismo de nivel profesional
- Edición por instrucciones
- Mantener estilo/personaje/producto entre variaciones
- Infografías, mockups y assets de marketing
- Uso de imágenes de referencia
- Grounding con búsqueda/contexto en modelos conectados

Limitaciones

- Texto muy largo todavía se degrada
- Consistencia perfecta entre muchas imágenes
- Manos/anatomía en poses complejas
- Logos y marcas exactas pueden fallar
- Control pixel-perfect sigue siendo difícil
- Personas reales específicas: restringido según plataforma
- Ediciones pequeñas pueden cambiar partes no solicitadas

¿Cómo generamos video?

Stable Diffusion... pero con tiempo

En imagen generamos un resultado estático desde ruido.
En vídeo generamos una secuencia de imágenes coherentes,
manteniendo personajes, objetos, estilo y movimiento entre frames.



Stable Diffusion



Adiós a Sora: OpenAI pone punto final a su "experimento" de vídeo con IA

Sora, la app de vídeo con IA de OpenAI que incluso aspiraba a competir con TikTok hace sólo unos meses, se despide ahora tras un crecimiento fulgurante y una caída igual de rápida: el interés inicial no se convirtió en un uso orgánico ni monetizable



Modelo	Duración	Audio	Calidad
Seedance 2.0	~ 10-15 segundos	Sí / según versión	★★★★★
Veo 3.1 (Oct 25)	~ 10 segundos	Nativo: diálogo, ambiente, SFX	★★★★☆
Kling 3.0	~ 10-15 segundos	Sí	★★★★☆
Runway Gen-4	~ 10 segundos	Limitado	★★★

Lo que YA funciona

- Clips cortos de calidad profesional
- Audio sincronizado: diálogo, ambiente y efectos
- Image-to-video desde una imagen de referencia
- Movimiento de cámara estable
- Estilos cinematográficos y publicitarios
- Variaciones rápidas para conceptos creativos

Limitaciones

- Consistencia en vídeos largos
- Personajes idénticos entre varias escenas
- Movimientos complejos: deportes, baile, peleas...
- Lip-sync perfecto en diálogo largo
- Control preciso plano a plano
- Texto dentro del vídeo
- Coste, latencia y límites de uso

Will Smith como benchmark

- Meme convertido en referencia: el vídeo de Will Smith comiendo espaguetis se usa como comparación visual del progreso a lo largo de los años
- Lo que antes fallaba: cara, manos, comida, física y coherencia temporal...
- Lo gracioso: cuanto menos “miedo” da, más ha avanzado el vídeo generativo.



La IA generativa llega a las redes sociales

- ¿Queremos saber cuándo un contenido ha sido generado por IA?
- ¿La IA hará las redes más creativas... o más falsas?
- ¿Qué pasa con influencers, marcas y creadores?
- ¿Deberían las plataformas etiquetar todo contenido sintético?
- ¿Nos preocupa más el engaño o la saturación de contenido?



¿Cómo generamos audio?

Stable Diffusion... pero aplicado al sonido

Igual que Stable Diffusion genera imágenes, Stable Audio genera sonido: parte de una representación ruidosa y la transforma paso a paso en música, voz o efectos de sonido.

Stable Diffusion



Modelo	Tipo	Calidad
ElevenLabs V3	TTS (Text to Speech)	★★★★★
GPT-Realtime	STS (Speech-to-Speech)	★★★★★
Scribe V (Eleven Labs)	STT (Text to Speech)	★★★★★
Whisper large v3	STT (Text to Speech)	★★★★★
Suno V5	Música	★★★★★

Lo que YA funciona

- **Voz conversacional real-time** (gpt-realtime-2)
- Clonación de voz con **1-2 min** de audio
- TTS con rango emocional amplio
- STT con **96.7% precisión** (Scribe v2)
- Música completa **hasta 8 min** (Suno v5)
- Diarización de hablantes
- 32+ idiomas soportados

Limitaciones

- **Canto en TTS** (aún robótico)
- **Emociones** muy sutiles
- **Música**: derechos legales inciertos
- **Clonación perfecta** requiere 2-3h audio de buena calidad

GenAI Providers



Tier 1: Los grandes

- **OpenAI:** GPT-5.5
- **Anthropic:** Claude Sonnet 4.7 y Opus 4.7
- **Google:** Gemini 3.1 Pro

Tier 3: Los especializados

- **Cohere:** Command A+ (Enterprise RAG)
- **DeepSeek:** V3.2
- **Alibaba:** Qwen3-Max

Tier 2: Competidores secundarios

- **Meta:** LLaMA 4 Maverick
- **DeepSeek:** DeepSeek v3.2
- **xAi:** Grok 4.3, Grok 4.3 Heavy

Open-Weight leaders

- **Meta:** Llama 4 Scout
- **Alibaba:** Qwen3 family
- **Mistral:** Medium 3
- **DeepSeek:** DeepSeek v3.2



 LLM Price Check

Made by **OpenL**

LLM Pricing

Compare and calculate the latest prices for LLM (Large Language Models) APIs from leading providers such as OpenAI GPT-4, Anthropic Claude, Google Gemini, Mate Llama 3, and more. Use our streamlined LLM Price Check tool to start optimizing your AI budget efficiently today!

Price Comparison

Pricing Calculator

 PDF Pals: Instantly chat with any PDF on your Mac. Sponsored

Search

Model	Provider	Quality	Context	Input \$/1M	Output \$/1M	Knowledge	Free trial
gpt-4o	OpenAI	100	128K	\$5	\$15	2023-10	Chat
gpt-4o-2024-08-06	OpenAI	100	128K	\$2.5	\$10	2023-10	Chat
gpt-4o-mini	OpenAI	85	128K	\$0.15	\$0.6	2023-10	Chat
gpt-4o-2024-05-13	OpenAI	100	128K	\$5	\$15	2023-10	Chat
gpt-4-turbo-2024-04-09	OpenAI	94	128K	\$10	\$30	2023-12	Chat
gpt-4	OpenAI	84	8K	\$30	\$60	2021-09	Chat
gpt-4-32k	OpenAI		32K	\$60	\$120	2021-09	Chat
gpt-3.5-turbo-0125	OpenAI	67	16K	\$0.5	\$1.5	2021-09	Chat
gpt-3.5-turbo-instruct	OpenAI	60	4K	\$1.5	\$2	2021-09	Chat

Latencia, Ventanas de contexto, Benchmarks...


Model ↑↓	Context Window ↑↓	Creator ↑↓	Artificial Analysis Intelligence Index ↑↓	CritPt (Physics Reasoning) ↑↓	MMMU Pro (Visual Reasoning) ↑↓	Blended USD/1M Tokens ↑↓	Median Tokens/s ↑↓	Latency First Answer Chunk (s) ↑↓	Further Analysis	
Gemini 3 Pro Preview (high)	1m	Google	73	9%	80%	\$4.50	0	0.00	Model	Providers
Claude Opus 4.5	200k	Anthropic	70	5%	74%	\$10.00	52	1.89	Model	Providers
GPT-5.1 (high)	400k	OpenAI	70	5%	76%	\$3.44	128	25.99	Model	Providers
GPT-5 Codex (high)	400k	OpenAI	68	--	74%	\$3.44	245	10.35	Model	Providers
GPT-5 (high)	400k	OpenAI	68	6%	74%	\$3.44	0	0.00	Model	Providers
Kimi K2 Thinking	256k	Moonshot AI	67	3%	--	\$1.07	90	0.82	Model	Providers
GPT-5 (medium)	400k	OpenAI	66	--	74%	\$3.44	0	0.00	Model	Providers
o3	200k	OpenAI	65	--	70%	\$3.50	199	12.22	Model	Providers
Grok 4	256k	xAI	65	2%	69%	\$6.00	0	0.00	Model	Providers
GPT-5 mini (high)	400k	OpenAI	64	--	70%	\$0.69	73	103.08	Model	Providers
Grok 4.1 Fast	2m	xAI	64	3%	63%	\$0.28	0	0.00	Model	Providers
Claude 4.5 Sonnet	1m	Anthropic	63	1%						
GPT-5 (low)	400k	OpenAI	62	--						
MiniMax-M2	205k	MiniMax	61	1%						
GPT-5 mini (medium)	400k	OpenAI	61	--						
gpt-oss-120B (high)	131k	OpenAI	61	1%						
Grok 4 Fast	2m	xAI	60	3%						
Claude Opus 4.5	200k	Anthropic	60	--						
Gemini 2.5 Pro	1m	Google	60	3%						
DeepSeek V3.1 Terminus	128k	DeepSeek	58	--						
Qwen3 235B A22B 2507	256k	Alibaba	57	1%						

Métricas Clave


- **TTFT** (Time To First Token) Cuánto esperas a que empiece la respuesta. Crítico para UX en chat.
- **TPS** (Tokens Per Second): Velocidad de generación. Importante para respuestas largas.

Observabilidad de los LLMs y calidad en producción

- Herramientas para ello: **Langfuse, Arizephoenix, LangSmith...**
- **Trazar cada interacción:** Ver prompt, respuesta, modelo, usuario, herramientas y pasos intermedios.
- **Medir coste y rendimiento:** Tokens, latencia, errores, throughput y coste por caso de uso.
- **Evaluar calidad real:** Revisar respuestas, detectar fallos y comparar versiones de prompts/modelos.
- **Recoger feedback de usuarios:** Likes/dislikes, correcciones, etiquetas y ejemplos problemáticos.
- **Crear datasets de evaluación continua:** Convertir casos reales en tests para evitar regresiones.
- **Monitorizar en producción:** Detectar degradación, alucinaciones, errores de herramientas o cambios de comportamiento.



- Herramientas: Ollama · LM Studio · vLLM...
- **Ejecutan modelos open-weight de manera fácil:** Llama, Mistral, Qwen, DeepSeek...
- **Probar y comparar modelos localmente:** Útil para demos, prototipos y validaciones técnicas.
- **Ganar privacidad y control:** Los datos pueden quedarse en tu portátil, servidor o infraestructura propia.
- **Reducir dependencia de APIs externas:** Menos lock-in con proveedores cloud.
- **Optimizar coste en ciertos casos:** No pagas por token, aunque necesitas hardware y mantenimiento.
- **Limitaciones**
 - Requiere recursos propios (GPU,RAM...)
 - Menor calidad que modelos frontier cerrados
 - Más responsabilidad operativa (Seguridad, actualizaciones, escalado...)
 - No siempre incluye funciones avanzadas




Buenas prácticas para usar LLMs en producción




Matriz de Decisión Práctica (Mayo 2026)

Caso de Uso	Modelo Recomendado	Razón
Chat alto volumen	GPT-5.5 mini / Gemini Flash / Claude Haiku	Coste bajo + baja latencia
Documentos complejos	Gemini 3 / Gemini 3.1 Pro Preview	Contexto largo y multimodal
Crear/Editar Presentaciones / documentos	GPT-5.5 / Claude Opus 4.7 / Gemini 3 Pro	Estructura, redacción, formato y generación de entregables
Análisis complejo / razonamiento	GPT-5.5 / Claude Opus 4.7 / Gemini 3 Pro	Mejor calidad en tareas difíciles
Multimodal general	GPT-5.5 / Gemini 3 Pro	Texto + imagen + audio/vídeo
Código y agentes	Claude Opus 4.7 / GPT-5.5	Buen rendimiento agentic/coding
Vídeo como input	Gemini 3 Pro	Comprensión de vídeo y contexto largo
Generación de vídeo	Veo / Runway / Kling	Modelos específicos de vídeo
On-premise / privacidad EU	Mistral / Llama / Qwen open-weight	GDPR + calidad
Presupuesto mínimo	DeepSeek / Qwen / modelos mini	Precios imbatibles
Open-weight frontier	Llama 4 / Qwen / DeepSeek / Mistral	Pesos abiertos o desplegados




Idea: ahorrar cuando repites mucho contexto.

- Reutiliza partes fijas del prompt entre llamadas.
- Útil para instrucciones largas, documentación, políticas o ejemplos.
- Reduce coste y puede reducir latencia.
- El ahorro suele aplicar sólo a los tokens repetidos/cacheados.
- Según proveedor/modelo, puede suponer entre ~50% y ~90% menos coste en esa parte.
- Funciona mejor si el contexto repetido aparece igual y al inicio.
- Ejemplo: 1.000 preguntas sobre el mismo manual.




- Procesar volumen cuando no necesitas respuesta inmediata.
- Envías muchas tareas juntas.
- Suele ser más 50% más barato que llamadas en tiempo real.
- Suele ser más rápido en grandes volúmenes pero no es seguro. (hasta 24h por ejemplo OpenAI)
- Ideal para clasificación, extracción, resúmenes o evaluaciones masivas.
- Ejemplo: analizar 50.000 tickets durante la noche.




Mejorar la experiencia de usuario.

- La respuesta aparece mientras el modelo la genera.
- No reduce necesariamente el coste total.
- Hace que la aplicación parezca más rápida.
- Ideal para chats, asistentes y generación de texto largo.
- No siempre es necesario



- No usar siempre el modelo más caro.
- Enviar cada tarea al modelo adecuado.
- Modelo pequeño para tareas simples.
- Modelo grande solo para razonamiento complejo.
- Puede reducir coste y latencia.
- Ejemplo: clasificar intención con modelo mini y resolver casos difíciles con modelo frontier.



No pedir texto libre si necesitas datos fiables.

- Forzar respuestas en JSON o esquema definido.
- Facilita validación automática.
- Reduce errores de formato.
- Ideal para integraciones, formularios, extracción de datos y workflows.
- Ejemplo: extraer {cliente, fecha, importe, categoría} de una factura.

**MUY IMPORTANTE EN PRODUCCIÓN,
SE USA MUCHÍSIMO!!!**

Outputs estructurados

En vez de texto libre, pedimos al modelo que responda en un **formato definido** (JSON).

Salida sin estructurar (texto libre)

El pedido fue realizado por María López el 12 de mayo de 2024. El total es de 129,98 euros y el estado actual es enviado. El número de pedido es el 98765. Los productos son una cámara (89,99€) y una tarjeta SD de 64GB (39,99€).



Salida estructurada (JSON)

```
{
  "numero_pedido": "98765",
  "cliente": "María López",
  "fecha_pedido": "2024-05-12",
  "estado": "enviado",
  "total_eur": 129.98,
  "productos": [
    {
      "nombre": "Cámara",
      "precio_eur": 89.99
    },
    {
      "nombre": "Tarjeta SD 64GB",
      "precio_eur": 39.99
    }
  ]
}
```

- ✓ Fácil de leer
- ✓ Fácil de validar
- ✓ Fácil de usar en tu aplicación

Esquema / JSON Schema (ejemplo simplificado)

```
{
  "type": "object",
  "properties": {
    "numero_pedido": {"type": "string"},
    "cliente": {"type": "string"},
    "fecha_pedido": {"type": "string", "format": "date"},
    "estado": {"type": "string", "enum": ["pendiente", "enviado", "entregado", "cancelado"]},
    "total_eur": {"type": "number"},
    "productos": {
      "type": "array",
      "items": {
        "type": "object",
        "properties": {
          "nombre": {"type": "string"},
          "precio_eur": {"type": "number"}
        },
        "required": ["nombre", "precio_eur"]
      }
    }
  },
  "required": ["numero_pedido", "cliente", "fecha_pedido", "estado", "total_eur", "productos"]
}
```

¿Cómo se usa?

- 1 Definimos el esquema (JSON Schema).
- 2 Se lo pasamos al modelo (en la API).
- 3 El modelo responde siempre en ese formato.
- 4 Validamos y usamos los datos en nuestra app.




LLMs en Data Science



LLMs en Data Science: ¿dónde ayudan?

No sustituyen al data scientist, aceleran tareas repetitivas.





La IA no sustituye el criterio analítico:
reduce el tiempo entre pregunta, código, análisis y entrega.



- **¿Qué puede hacer la IA?**
 - Sugerir visualizaciones según el tipo de variable y la pregunta de negocio
 - Detectar outliers, patrones y anomalías para investigar
 - Generar queries de análisis en SQL, pandas o PySpark
 - Explicar correlaciones y segmentos en lenguaje natural
 - Proponer hipótesis a partir de los datos disponibles
- **Ejemplos**
 - “¿Qué variables parecen explicar mejor la caída de ventas?”
 - “Dame 5 visualizaciones útiles para entender churn.”
 - “Resume los principales patrones de este dataset para un comité.”
- **Cuidado importante**
 - La IA puede sugerir hipótesis, pero los números deben venir del dataset
 - No aceptar conclusiones sin validar cálculos, filtros y supuestos
 - Usar la IA como copiloto analítico, no como verdad absoluta
 - El analista debe poder explicar qué se hizo, por qué y con qué datos




- **¿Qué es?**
 - Framework en Python para crear aplicaciones web interactivas sin tener que saber frontend.
- **¿Para qué sirve?**
 - Convertir notebooks en herramientas interactivas
 - Crear dashboards rápidos para negocio
 - Subir CSVs, filtrar datos y visualizar resultados
 - Poner un frontal a PoC de manera fácil
- **Por qué es útil**
 - Muy rápido para prototipar
 - Se programa en Python
 - Integra bien con:
 - Pandas/ NumPy: `st.dataframe(df) · st.metric("Ventas", total)`
 - Plotly: `st.plotly_chart(fig)`
 - scikit-learn: `model.predict(X)`
 - LLMs y APIs: `client.responses.create(...)`
 - Bases de datos... : `pd.read_sql(query, conn)`
 - Permite validar ideas antes de invertir en una app completa
- **Limitaciones**
 - Hay que cuidar seguridad, permisos y despliegue si se usa en producción
 - Para mucho tráfico o UX avanzada, puede quedarse corto




Data wrangling asistido por IA

Usar LLMs para preparar datos más rápido.

- Detectar columnas, tipos y valores raros
- Proponer reglas de limpieza
- Normalizar formatos: fechas, países, monedas, categorías
- Generar código pandas / PySpark / SQL...
- Crear features nuevas
- Documentar transformaciones
- Ejemplo: “Tengo una columna fecha_alta con formatos mezclados y una columna importe con símbolos de moneda. La IA puede proponer el código para limpiarlas, pero hay que validar el resultado.”



- Preguntar en lenguaje natural y obtener consultas SQL.
- El usuario pregunta: “¿Ventas por país en los últimos 6 meses?”
- El sistema entiende el esquema de la base de datos
- Genera SQL
- Ejecuta o propone la consulta
- Devuelve tabla, gráfico o explicación
- Herramientas / enfoques:
 - **Vanna:** text-to-SQL entrenado con tu esquema, queries y documentación.
 - **Snowflake Cortex Analyst:** preguntas en lenguaje natural sobre datos en Snowflake.
 - **Databricks Genie:** conversación sobre datos gobernados en Lakehouse.
 - **Microsoft Fabric / Power BI Copilot:** análisis y reporting asistido.
- Importante:
 - Text-to-SQL funciona mejor cuando el modelo conoce bien el esquema, las métricas y las reglas de negocio.



Ejercicio Text-to-SQL



- ¿Qué es?
 - Servicio de Snowflake Cortex para hacer preguntas en lenguaje natural sobre datos estructurados.
 - Convierte preguntas de negocio en consultas SQL.
 - Ejecuta el SQL directamente sobre las tablas en Snowflake.
-
- Cómo funciona
 1. El usuario pregunta en lenguaje natural:

“¿Ventas por país en el último trimestre?”
 2. Cortex Analyst interpreta la pregunta usando una capa semántica.
 3. Genera una consulta SQL.
 4. Snowflake ejecuta la query.
 5. Devuelve el resultado: tabla, explicación o visualización.
- Por qué necesita capa semántica
 - El esquema de una base de datos no siempre explica el negocio.
 - Hay que definir:
 - métricas: ventas, margen, churn, conversión...
 - dimensiones: país, canal, producto, segmento...
 - relaciones entre tablas
 - sinónimos y descripciones



Ejercicios Opcionales



Ejercicio 1 – Dashboard interactivo

https://github.com/alexoli97/MasterEBIS/blob/main/Lab_Streamlit_Alumnos.ipynb

Construir un dashboard con el dataset Palmer Penguins.

Objetivos:

- Títulos y textos básicos con Streamlit
- Filtros en la sidebar
- Condiciones de filtrado con pandas
- Métricas principales con st.metric()
- Vista de datos con st.expander() y st.dataframe()

Resultado:

Una app interactiva para filtrar datos, visualizar métricas y explorar gráficos.

Ejercicio 2 – Text-to-SQL con Vanna

Link al cuaderno Colab:

https://github.com/alexoli97/MasterEBIS/blob/main/Lab_TextToSQL_Vanna_Alumnos.ipynb

Crear un asistente que convierte preguntas en español en consultas SQL.

Objetivos:

- Crear una base SQLite desde pandas
- Definir el esquema de datos
- Añadir documentación del dataset
- Escribir ejemplos de preguntas y SQL
- Generar SQL con Vanna
- Visualizar resultados con Plotly

Resultado:

Un mini chatbot capaz de responder preguntas sobre datos usando SQL.



A detailed black and white illustration of a large, dense crowd of people, likely in a lecture hall or classroom. The people are depicted with various expressions and are holding up books or papers. In the background, a chalkboard is visible with some illegible writing. The entire scene is framed by a thick, dark border. Overlaid in the center of the image is the text 'Q&A' in a large, white, sans-serif font.

Q&A

KAHOOT!

Kahoot!



EBIS Business
Techschool

www.ebiseducation.com

